Normalisasi
Bagian I

First Normal Form (1NF)

- Domain disebut atomic bila elemen yang ada di dalamnya tidak dapat dibagi menjadi unit yang lebih kecil (*indivisible*)
- Sebuah skema relasi R berada dalam kondisi 1NF jika domain seluruh atribut dalam R atomic
- Nilai non-atomic membuat penyimpanan data menjadi rumit dan dapat mendorong terjadinya redundansi data. Contoh : himpunan account yang disimpan untuk tiap customer, dan himpunan pemilik yang disimpan untuk tiap account

Contoh

(a)

(b)

DEPARTMENT

DNAME	DNUMBER	DMGRSSN	DLOCATIONS
Research	5	333445555	{Bellaire, Sugarland, Houston}
Administration	4	987654321	{Stafford}
Headquarters	1	888665555	{Houston}

(c)

DEPARTMENT

DNAME	DNUMBER	DMGRSSN	DLOCATION
Research	5	333445555	Bellaire
Research	5	333445555	Sugarland
Research	5	333445555	Houston
Administration	4	987654321	Stafford
Headquarters	1	888665555	Houston

Contoh

(a) **EMP_PROJ**

SSN	FNAME	PROJS	
		PNUMBER	HOURS

(b) **EMP_PROJ**

SSN	ENAME	PNUMBER	HOURS
123456789	Smith,John B.	1	32.5
		2	7.5
666884444	Narayan,Ramesh K.	3	40.0
453453453	English,Joyce A.	1	20.0
		2	20.0
333445555	Wong,Franklin T.	2	10.0
		3	10.0
		10	10.0
		20	10.0
999887777	Zelaya,Alicia J.	30	30.0
		10	10.0
987987987	Jabbar,Ahmad V.	10	35.0
		30	5.0
987654321	Wallace,Jennifer S.	30	20.0
		20	15.0
888665555	Borg,James E.	20	null

(c) **EMP_PROJ1**

SSN	ENAME

EMP_PROJ2

SSN	PNUMBER	HOURS

Pitfalls dalam Perancangan Basis Data Relasional

- Perancangan basis data relasional mensyaratkan penggunaan kumpulan relasi skema yang baik. Perancangan yang buruk dapat menyebabkan :
  - Pengulangan informasi
  - Ketidakmampuan dalam merepresentasikan informasi tertentu
- Tujuan perancangan :
  - Menghindari redundansi data
  - Memastikan keterhubungan antar atribut dapat direpresentasikan
  - Memfasilitasi pengecekan update yang menyebabkan pelanggaran integritas constraint basis data
- Contoh :

  lending-schema = (branch-name, branch-city, assets, customer-name, loan-number, amount)

branch-name	*branch-city*	*assets*	*customer-name*	*loan-number*	*amount*
Downtown	Brooklyn	9000000	Jones	L-17	1000
Redwood	Palo Alto	2100000	Smith	L-23	2000
Perryridge	Horseneck	1700000	Hayes	L-15	1500
Downtown	Brooklyn	9000000	Jackson	L-14	1500

Pitfalls dalam Perancangan Basis Data Relasional (lanj.)

- Permasalahan dalam instan lending-schema :
  - Redundansi
    - Data untuk branch-name, branch-city, dan assets diulangi untuk tiap loan yang dibuat
    - Tempat yang terbuang percuma
    - Proses update yang rumit, dapat menyebabkan inkonsistensi nilai atribut, contohnya untuk atribut assets
  - Nilai null
    - Tidak dapat menyimpan informasi tentang sebuah branch apabila tidak ada loan
    - Dapat diselesaikan dengan penggunaan nilai null, tetapi nilai null sulit ditangani

Decomposition

- Skema relasi lending-schema didekomposisi menjadi :
  - Branch-schema = (branch-name, branch-city, assets)
  - Loan-info-schema = (customer-name, loan-number, branch-name, amount)
- Seluruh atribut dari skema asli (R) harus muncul di skema hasil dekomposisi (R_1, R_2) :

  $R = R_1 \cup R_2$
- *Lossless join decomposition*

  untuk semua kemungkinan relasi r dalam skema R

$$r = \Pi_{R1}(r) \bowtie \Pi_{R2}(r)$$

Decomposition (lanj.)

- Contoh dekomposisi yang tidak memenuhi kondisi *lossless join decomposition*,

  R = (A,B) didekomposisi menjadi R_1=(A) dan R_2=(B)

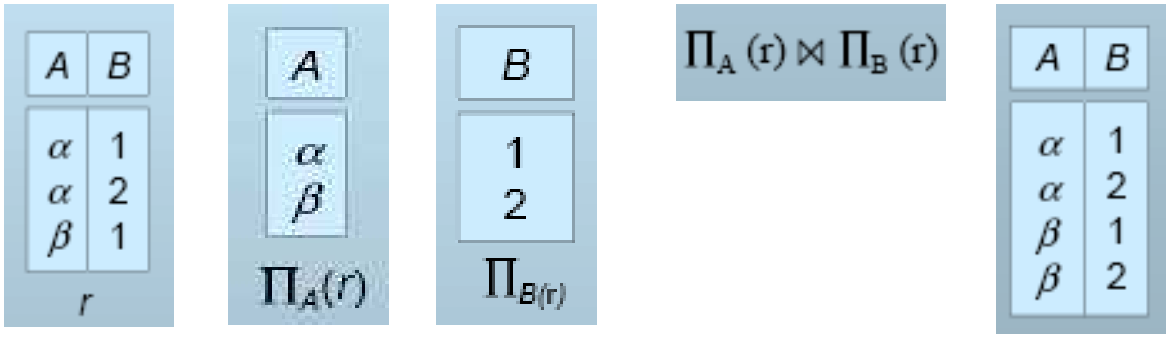

Tujuan Normalisasi

- Menentukan apakah relasi tertentu berada dalam "*good form*"
- Dalam kasus di mana relasi R tidak berada dalam "*good form*", maka relasi tersebut didekomposisi menjadi himpunan relasi {R_1, R_2, …, R_n} di mana :
  - Setiap relasi berada dalam "*good form*"
  - Dekomposisi memenuhi syarat *lossless join decomposition*
- Normalisasi dilakukan berdasarkan :
  - *Functional dependencies*
  - *Multivalues dependencies*

Lossless Join Decomposition

- Untuk setiap kemungkinan relasi r dalam skema R

$$r = \Pi_{R1}(r) \bowtie \Pi_{R2}(r)$$

- Sebuah dekomposisi R menjadi R_1 dan R_2 dikatakan *lossless join* jika dan hanya jika paling tidak satu dari *dependency* berikut berada dalam F^+ :
  - $R_1 \cap R_2 \rightarrow R_1$
  - $R_1 \cap R_2 \rightarrow R_2$

  Jika tidak, maka dekomposisi yang dihasilkan akan menjadi lossy

Normalisasi Menggunakan *Functional Dependency*

- Saat kita melakukan dekomposisi sebuah skema relasi R dengan himpunan *functional dependency* F menjadi R_1, R_2, R_3, …, R_n kita menginginkan :
  - *Lossless join decomposition* : apabila kondisi ini tidak terpenuhi, dapat menyebabkan hilangnya informasi
  - Tidak terdapat redundansi : relasi R_i lebih disukai berada dalam kondisi Boyce-Codd Normal Form atau Third Normal Form
  - Dependency preservation : misal F_i adalah himpunan dependency F^+ yang hanya mengandung atribut dalam R_i
    - Lebih disukai dekomposisi memenuhi kondisi *dependency preserving*, yaitu : $(F_1 \cup F_2 \cup \ldots F_n)^+ = F^+$
    - Bila tidak memenuhi kondisi *dependency preserving*, untuk mencek pelanggaran *functional dependency* harus dilakukan join

Contoh

- R = (A,B,C)

  F = {A $\rightarrow$ B, B $\rightarrow$ C}

  dapat didekomposisi menggunakan dua cara :
- R_1 = (A,B), R_2 = (B,C)
  - Lossless join decomposition

    $R_1 \cap R_2$ = {B} dan B $\rightarrow$ C
- R_1 = (A,B), R_2 = (A,C)
  - Lossless join decomposition

    $R_1 \cap R_2$ = {A} dan A $\rightarrow$ B

Test untuk Dependency Preservation

- Untuk mencek apakah sebuah *dependency* $\alpha \rightarrow \beta$ *preserved* pada dekomposisi R menjadi R_1, R_2, …, R_n, dapat menggunakan prosedur berikut :
  - result = α
    while (changes to result) do
      for each R_i in decomposition
        t = (result ∩ R_i)$^+$ ∩ R_i
        result = result U t
  - Jika result mengandung semua atribut dalam β, maka *functional dependency* α->β *preserved*
- Test tersebut diterapkan pada semua dependency di F untuk mencek apakakah sebuah dekomposisi memenuhi syarat *dependency preserving*
- Prosedur tersebut memerlukan *polynomial time* dalam pemrosesannya

Second Normal Form (2NF)

- Sebuah relasi berada dalam kondisi 2NF jika dan hanya jika relasi tersebut :
  - Berada dalam kondisi 1NF
  - Tidak ada atribut nonkey yang tergantung secara parsial dengan relasi dalam skema tersebut

Third Normal Form (3NF)

- Sebuah relasi berada dalam kondisi 3NF jika dan hanya jika :
  - Berada dalam kondisi 2NF
  - Setiap atribut nonkey bersifat *nontransitively dependent* pada *primary key*
- Functional dependency $X \rightarrow A$ pada F^+ disebut transitive jika $X \rightarrow Y$ dan $Y \rightarrow A$ ada di F^+, dan $Y \rightarrow X$ tidak ada di F^+
- 3NF mengasumsikan relasi hanya mempunyai satu *candidate key*
- 3NF tidak cukup memecahkan persoalan pada kasus di mana sebuah relasi :
  - Mempunyai dua atau lebih *candidate key*, di mana
  - *Candidate key* tersebut komposit
  - Terdapat overlap

Definisi Formal 3NF

- Sebuah skema relasi R berada dalam kondisi 3NF jika untuk semua $\alpha \rightarrow \beta$ dalam F^+ paling tidak satu kondisi berikut terpenuhi :
  - $\alpha \rightarrow \beta$ trivial (misal, $\beta \varepsilon \alpha$)
  - α adalah *superkey* untuk R
  - Setiap atribut A dalam $\beta - \alpha$ terkandung dalam sebuah *candidate key* untuk R (tiap atribut dapat berada dalam *candidate key* yang berbeda)
- Contoh :
  - R = (J,K,L), F = {JK $\rightarrow$ L, L $\rightarrow$ K}
  - Dua *candidate key* : JK dan JL
  - R berada dalam kondisi 3NF :
    - JK $\rightarrow$ L JK adalah *superkey*
    - L $\rightarrow$ K K terkandung dalam sebuah *candidate key*

Testing untuk 3NF

- Optimization : hanya perlu mencek *functional dependency* dalam F, tidak perlu mencek seluruh functional dependency dalam F^+
- Menggunakan *closure* atribut untuk mencek setiap *dependency* α->β, apakah α superkey
- Jika α bukan superkey, harus dilakukan verifikasi untuk tiap atribut dalam β apakah terkandung dalam sebuah *candidate key* R

Tujuan Perancangan

- Tujuan dalam perancangan basis data relasional :
  - Lossless join
  - Dependency preservation
- Bila tujuan tersebut tidak dapat tercapai, akan terjadi :
  - Tidak mempunyai dependency preservation
  - redundansi
- SQL tidak menyediakan cara untuk menyatakan functional dependency selain penggunaan superkey. Bisa diterapkan menggunakan assertion, tetapi biayanya mahal.
- Bahkan jika hasil dekomposisi yang kita peroleh memenuhi syarat dependency preserving, penggunaan SQL tidak mampu untuk mentest secara efisien sebuah functional dependency yang sisi kirinya bukan merupakan key

Proses Perancangan Basis Data Secara Umum

- Kita mengasumsikan sebuah skema R yang tersedia :
  - R dapat merupakan hasil saat mengubah diagram ER menjadi himpunan tabel
  - R dapat merupakan sebuah relasi tunggal yang mengandung semua atribut yang terhubung (disebut sebagai relasi universal)
  - Normalisasi memecah R menjadi beberapa relasi yang lebih kecil
  - R dapat merupakan hasil dari beberapa perancangan ad hoc relasi, yang kemudian ditest/diubah menjadi bentuk normal

ER Model dan Normalisasi

- Saat sebuah diagram ER dirancang secara hati-hati, semua entitas didientifikasi secara benar, tabel yang di-generate dari diagram ER tersebut seharusnya tidak memerlukan proses normalisasi lagi
- Bagaimanapun, dalam kenyataannya perancangan dapat mengandung FD dari atribut nonkey ke atribut lainnya
- Contoh : entitas employee dengan atribut department-number dan department-address, dan sebuah FD department-number -> department-address
  - Perancangan yang baik akan membuat department sebagai sebuah entitas
- FD dari atribut nonkey dimungkinkan, tetapi jarang, sebagian besar relationship adalah binary

Denormalisasi untuk Performansi

- Dalam beberapa kondisi, kita mungkin menggunakan skema non-normalized untuk meningkatkan performansi
- Contoh : untuk menampilkan customer-name bersama account-number dan balance membutuhkan join antara entitas account dan depositor
- Alternatif 1 : menggunakan denormalized relation yang mengandung atribut dari account dan juga dari depositor
  - Lookup lebih cepat $account \bowtie depositor$
  - Membutuhkan tempat dan waktu ekstra pada update
  - Membutuhkan coding ekstra serta kemungkinan munculnya error
- Alternatif 2 : menggunakan materialized view yang didefinisikan dengan
  - Manfaat dan kekurangan sama dengan alternatif 1, selain tanpa ekstra coding dan menghindari error yang mungkin

Persoalan Perncangan Lainnya

- Beberapa aspek dalam perancangan basis data tidak ditangai dengan normalisasi
- Contoh : perancangan basis data yang buruk, yang harus dihindari :
- Daripada menggunakan earnings (company-id, year, amount), gunakanlah :
  - Earnings-2000, earnings-2001, earnings-2002, etc, semuanya dalam skema (company-id, earnings)
    - Seluruh relasi tersebut dalam BCNF, tetapi sulit membuat query yang meliputi beberapa year, dan jumlah tabel semakin bertambah sesuai dengan tahun
  - Company-year(company-id, earnings-2000, earnings-2001, earnings-2002)
    - Dalam BCNF juga, tetapi query yang melibatkan tahun yang berbeda juga sulit, dan untuk setiap tahun diperlukan atribut tambahan baru
    - Merupakan contoh dari crosstab, di mana nilai untuk sebuah atribut menjadi nama kolom
    - Digunakan dalam spreadsheet, dan dalam tools analisis data